TAGFlow: Decoding Customer Sequences via Multi-Task Neural Networks

Trần Nam Hải, Nguyễn Vũ Trung Kiên, Phạm Tiến Dũng
Trường Công nghệ Thông tin và Truyền thông, Đại học Bách Khoa Hà Nội, Việt Nam
Email: {trannamhai.5d, ngkienn89, tiendungcbh1801}@gmail.com

Đội thi HD4K - Vòng bán kết cuộc thi DataFlow 2026

***Tóm tắt nội dung*—Trong bối cảnh thương mại điện tử hiện đại, dự báo chính xác hành vi mua sắm của khách hàng là bài toán then chốt nhằm tối ưu hóa chuỗi cung ứng và quản trị rủi ro tồn kho. Tuy nhiên, việc dự đoán đồng thời đa thuộc tính mục tiêu từ các chuỗi tương tác ẩn danh có độ dài biến thiên đặt ra thách thức lớn về hiện tượng dịch chuyển phân phối và sự phức tạp của các luồng hành vi phi tuyến. Để giải quyết vấn đề này, bài báo cáo đề xuất TAGFlow - hệ thống học sâu đa nhiệm dự báo sớm 6 thuộc tính hành vi khách hàng trong thương mại điện tử. Đóng góp cốt lõi bao gồm ba giải pháp: (1) Quy trình huấn luyện hai giai đoạn kết hợp nhãn giả giúp khắc phục dịch chuyển phân phối; (2) Hàm mất mát *Max-Penalty* cưỡng chế mô hình tập trung vào các thuộc tính khó, tối ưu hóa trực tiếp thước đo Exact-Match (EM); và (3) Kiến trúc TAGNet dựa trên Mạng nơ-ron Đồ thị (GNN) kết hợp *AttentionPooling1D* nhằm lập bản đồ hành vi phi tuyến. Thực nghiệm chứng minh sự vượt trội của TAGFlow khi đạt Val EM > 0.996 và Public Test EM đạt 0.9725. Hệ thống cũng cung cấp khả năng giải thích minh bạch (*xAI*), trực tiếp chuyển hóa thành các chiến lược quản trị kho bãi chủ động và tiếp thị cá nhân hóa cho doanh nghiệp. Mã nguồn khả dụng tại: https://github.com/CryAndRRich/tagflow.**

***Từ khoá*—Dự đoán hành vi người dùng, Multi-task Learning, Variable-length Sequence, Exact-Match Accuracy.**

I. GIỚI THIỆU BÀI TOÁN

Trong bối cảnh thương mại điện tử hiện đại, tối ưu hóa chi phí vận hành kho bãi là thách thức sống còn đối với các doanh nghiệp quy mô lớn. Quản lý kho bãi bị động truyền thống thường dẫn đến rủi ro tồn kho quá mức hoặc đứt gãy chuỗi cung ứng. Do đó, việc xây dựng hệ thống dự báo sớm hành vi mua sắm của khách hàng là bài toán cấp thiết, giúp đội ngũ kinh doanh chủ động phân tích và tối ưu hóa chiến lược phân bổ nguồn lực.

Trong khuôn khổ vòng bán kết cuộc thi "*DataFlow 2026: The Alchemy of Minds*", thử thách "Dự đoán hành vi người dùng" yêu cầu giải quyết bài toán phân loại đa đầu ra (*Multi-output Classification*). Cụ thể, hệ thống phải dự báo đồng thời 6 thuộc tính hành vi độc lập dựa trên dữ liệu quá khứ của khách hàng.

Tập dữ liệu mang những thách thức khai phá đặc thù:

- **Đầu vào (Input):** Chuỗi hành động ẩn danh của người dùng trong 4 tuần. Đặc trưng cốt lõi là độ dài chuỗi biến thiên (*variable-length sequences*) do tần suất tương tác của mỗi cá nhân không đồng nhất.
- **Đầu ra (Output):** 6 biến mục tiêu định dạng `UINT16`, đại diện cho 6 khía cạnh độc lập và không có mối liên hệ trực tiếp.

Cuộc thi sử dụng thước đo **Exact-Match Accuracy** (Độ chính xác khớp tuyệt đối), đòi hỏi mô hình suy luận chính xác đồng thời cả 6 giá trị cho mỗi dự đoán.

Tiếp nối thành công từ vòng loại, đội thi HD4K đề xuất hệ thống **TAGFlow** với chiến lược giải quyết bài toán xoay quanh ba trụ cột cốt lõi:

- **Quy trình huấn luyện 2 giai đoạn (*2-Stage Pipeline*):** Giải quyết triệt để thách thức từ dữ liệu chuỗi biến thiên và tối ưu hóa thước đo Exact-Match. Quy trình này cho phép học hỏi biểu diễn, sàng lọc và tinh chỉnh dự báo từ mức độ đơn thuộc tính lên đa thuộc tính một cách chặt chẽ.
- **Nhóm mô hình học sâu Temporal Actions Network:** Hệ sinh thái gồm 4 kiến trúc mạng đa nhiệm tối ưu hóa đồng thời 6 đầu ra. Bao gồm: **TACNet** (Convolutional) trích xuất đặc trưng cục bộ, **TARNet** (Recurrent) học phụ thuộc dài hạn, và **TAANet** (Attention) tập trung vào các hành vi trọng yếu. Trong đó, **TAGNet** (Temporal Actions Graph) đóng vai trò kiến trúc chủ lực, ứng dụng Mạng nơ-ron Đồ thị (GNN) [1] để lập bản đồ các tương tác phi tuyến phức tạp nhất.
- **Định hướng giải quyết nghiệp vụ:** Chuyển hóa các kết quả dự báo kỹ thuật thành chiến lược quản lý tồn kho thực tiễn. Giải pháp hỗ trợ doanh nghiệp chủ động phân bổ nguồn lực, xử lý hiệu quả các trường hợp ngoại lai (*edge cases*) và các luồng thay đổi đơn hàng phức tạp.

II. PHÂN TÍCH DỮ LIỆU

A. *Tổng quan về bộ dữ liệu*

Bộ dữ liệu bao gồm giao dịch thực tế đã qua xử lý ẩn danh, ghi nhận chuỗi hành vi của 51.000 khách hàng trong tập huấn luyện. Cấu trúc dữ liệu được thiết kế nhằm mô phỏng lộ trình tương tác của người dùng và các hệ quả nghiệp vụ tương ứng:

Dữ liệu đầu vào là các chuỗi hành động theo thời gian phát sinh trong 4 tuần. Nhằm đảm bảo tính bảo mật, toàn bộ danh mục hành động được mã hóa thành định danh số nguyên. Đặc trưng cốt lõi của dữ liệu là tính biến thiên về độ dài chuỗi (dao động từ 3 đến 37 hành động), phản ánh sự đa dạng trong tần suất và thói quen tương tác đặc thù của từng cá nhân.

Dữ liệu đầu ra bao gồm 6 biến mục tiêu độc lập (`attr_1` đến `attr_6`), đại diện cho các chỉ số chiến lược hỗ trợ tối ưu hóa chuỗi cung ứng. Việc dự báo chính xác các thuộc tính này giúp đội ngũ vận hành chủ động trong kế hoạch nhập hàng. Đáng chú ý, các biến mục tiêu sở hữu không

gian nhãn khác nhau (lần lượt là $12, 31, 99, 12, 31$ và 99 lớp) và không tồn tại mối liên hệ logic trực tiếp.

B. Phân tích đặc trưng và Insight nghiệp vụ

Hệ thống **TAGFlow** được xây dựng không chỉ dựa trên tối ưu toán học, mà còn bắt nguồn từ việc giải mã "ngôn ngữ hành vi" và cấu trúc phân cấp danh mục hàng hóa.

Bảng I: Thống kê tần suất xuất hiện và vị trí các mã hành động

Mã hành động	Tổng số lần	Tỷ lệ bắt đầu	Tỷ lệ kết thúc
105.0	56.478	0.0000	0.0000
102.0	41.036	0.0000	0.0037
103.0	25.704	0.0000	0.0025
760.0	18.524	0.4441	0.0003
8615.0	18.396	0.0000	0.0015
685.0	16.949	0.4672	0.0005
697.0	13.856	0.0000	0.0003
867.0	10.537	0.3622	0.0087
929.0	10.270	0.3600	0.0121
975.0	9.564	0.0000	0.3643
606.0	9.532	0.0000	0.0018
836.0	9.368	0.4433	0.0000
7943.0	9.345	0.4404	0.0000
1165.0	9.331	0.0000	0.0006
10477.0	9.261	0.4431	0.0005

1) Động lực học chuỗi hành động: Thông qua thống kê tần suất và vị trí xuất hiện của các mã định danh (Bảng I), chúng tôi phân tách chuỗi tương tác thành 3 giai đoạn chiến lược:

- **Nhóm hành động khởi đầu:** Các mã `760`, `685`, `836` chiếm tỷ trọng áp đảo tại vị trí đầu chuỗi. Đây là các hành vi mang tính chất "truy cập", đại diện cho việc mở ứng dụng hoặc truy cập trang chủ từ quảng cáo/tìm kiếm tự nhiên.
- **Nhóm điều hướng trung gian:** Mã `105` (cùng với `102`, `103`) đóng vai trò "nút thắt" điều hướng với tỷ lệ chuyển hướng (*outgoing transitions*) lên tới $99,31\%$. Đây là các chức năng cốt lõi như Trang chủ hoặc Xem chi tiết sản phẩm. Các mã liên quan đến sản phẩm thường bị "kẹp giữa" các mã này, phản ánh quá trình cân nhắc liên tục trước khi quyết định.
- **Nhóm hành động kết thúc:** Các mã `1027`, `995`, `1080` thường xuyên chốt lại chuỗi hành vi, đại diện cho kết quả của phiên giao dịch: thanh toán thành công, hủy đơn hoặc thoát ứng dụng.

2) Giả thuyết về hệ thống thuộc tính dự báo: Dựa trên phân phối và đặc thù không gian nhãn, chúng tôi xác lập giả thuyết về cấu trúc của 6 biến mục tiêu. Hệ thống dự báo được chia thành hai nhóm đại diện cho hai sản phẩm tiềm năng trong một phiên giao dịch: Nhóm 1 (`attr_1`, `attr_2`, `attr_3`) và Nhóm 2 (`attr_4`, `attr_5`, `attr_6`).

- **Ngành hàng lớn** (`attr_1` và `attr_4`): Gồm 12 giá trị duy nhất, đại diện cho các ngành hàng cấp cao (Điện tử, Thời trang, Gia dụng). Đây là chỉ số then chốt để lập kế hoạch ngân sách và điều phối nguồn lực quy mô lớn.
- **Danh mục sản phẩm** (`attr_2` và `attr_5`): Gồm 31 giá trị, trong đó mã số 1 chiếm tỷ trọng áp đảo, đại diện cho nhóm hàng thiết yếu có tốc độ tiêu thụ nhanh (FMCG). Việc dự báo chính xác giúp tối ưu hóa vị trí lưu kho và đẩy nhanh tốc độ đóng gói.
- **Thương hiệu và mã chi tiết** (`attr_3` và `attr_6`): Gồm 99 giá trị duy nhất với độ biến động cao nhất. Đây là cơ sở thiết lập ngưỡng tồn kho an toàn, duy trì nguồn cung ổn định cho các thương hiệu có nhu cầu cao.

3) Logic nghiệp vụ từ sự tương quan đa mục tiêu: Phân tích tương quan giữa 6 thuộc tính đầu ra hé lộ những quy luật mua sắm thực tiễn sau:

- **Nghịch lý tính đa dạng:** Tỷ lệ trùng khớp hoàn toàn giữa bộ nhãn sản phẩm 1 và sản phẩm 2 chỉ ở mức $0,05\%$. Khách hàng hiếm khi mua hai sản phẩm giống hệt nhau trong một phiên, mà thường chọn sản phẩm bổ trợ hoặc khác biệt.
- **Quán tính ngành hàng:** Mặc dù 6 biến độc lập, tỷ lệ trùng khớp ở cấp độ ngành hàng lớn đạt $25,13\%$ và danh mục trung đạt $27,82\%$. Insight này gợi mở rằng người dùng có xu hướng tập trung mua sắm trong cùng một hệ sinh thái danh mục.

Những phân tích trên khẳng định bài toán không chỉ dừng ở phân loại kỹ thuật, mà là nắm bắt sự chuyển dịch tâm lý từ thăm dò sang quyết định. Mô hình hóa thành công các giả thuyết này là chìa khóa nâng cao độ chính xác Exact-Match và mang lại giá trị thực tế cho doanh nghiệp. Đối với các phân tích chi tiết hơn về hành vi chuỗi và các thuộc tính, vui lòng tham khảo các Phụ lục A, B, C.

III. XỬ LÝ DỮ LIỆU

Để đảm bảo chất lượng đầu vào cho mạng nơ-ron và ngăn chặn hiện tượng học vẹt (*memorization*), quy trình tiền xử lý và tăng cường dữ liệu được thiết kế nghiêm ngặt. Phân tích thăm dò (EDA) đã chỉ ra các điểm bất thường và sự dịch chuyển phân phối, đòi hỏi kỹ thuật can thiệp chuyên sâu.

A. Làm sạch và Khắc phục rò rỉ dữ liệu

Tính toàn vẹn của tập kiểm định (Validation) là yếu tố tiên quyết để đánh giá đúng năng lực tổng quát hóa. Chúng tôi tiến hành xử lý hai vấn đề lớn:

- **Dữ liệu trùng lặp nội bộ (*Duplicates*):** Loại bỏ 29 cặp bản ghi trùng lặp trong tập Train và 6 cặp trong tập Validation nhằm tránh thiên lệch.
- **Hiện tượng rò rỉ dữ liệu (*Data Leakage*):** Phân tích phát hiện 8 chuỗi hành vi trong tập Validation trùng khớp hoàn toàn với tập Train. Để tuân thủ nguyên tắc đánh giá độc lập, các bản ghi rò rỉ này đã được loại trừ khỏi tập Validation.

B. Xử lý mất cân bằng phân phối chuỗi ngắn

Thông qua phân tích phân bố độ dài chuỗi hành động, chúng tôi ghi nhận một sự chênh lệch nghiêm trọng về phân bố độ dài chuỗi giữa dữ liệu huấn luyện và thực tế. Nhóm người dùng ít tương tác (độ dài ≤ 5) chiếm tỷ trọng rất nhỏ trong tập Train/Val (dưới 600 mẫu), nhưng lại áp đảo trên tập Test với hơn 4000 mẫu.

Sự chênh lệch này gây rủi ro suy giảm hiệu suất dự báo trên chuỗi ngắn. Để khắc phục, chúng tôi áp dụng chiến lược **Nhân bản dữ liệu thiểu số (*Oversampling*)**. Các chuỗi ngắn trong tập Train được nhân bản 40 lần, ép mạng

nơ-ron trích xuất đặc trưng cẩn thận hơn đối với các phiên giao dịch thưa thớt (*sparse interactions*).

C. Tăng cường dữ liệu chuỗi

Chúng tôi triển khai hai kỹ thuật tăng cường ngẫu nhiên trong quá trình nạp dữ liệu nhằm gia tăng tính bền vững (*robustness*):

- **Giãn nở chuỗi ngẫu nhiên (*Random Sequence Dilation*):** Các thực nghiệm nội bộ cho thấy khoảng cách thời gian vật lý giữa các hành động không mang tính quyết định tuyệt đối đến logic hành vi. Với xác suất 50%, chúng tôi chèn ngẫu nhiên mã 0 (trạng thái "không tương tác") vào giữa các hành động thực tế. Cơ chế nhiễu an toàn này giúp mô hình học được tính bất biến về không gian (*spatial invariance*), hiểu sâu về tính thứ tự thay vì phụ thuộc khoảng cách liền kề.
- **Che lấp ngẫu nhiên (*Random Masking*):** Lấy cảm hứng từ cơ chế Masked Language Modeling [2], chúng tôi tiến hành che lấp ngẫu nhiên 10% hành động trong chuỗi (thay bằng mã 0). Phương pháp này hoạt động như cơ chế điều chuẩn (*Regularization*), ngăn chặn hiện tượng quá tự tin (*overconfident*) hoặc học thuộc lòng các chuỗi hành động cụ thể, khiến mô hình buộc phải suy luận dựa trên bối cảnh toàn cục.

IV. PHƯƠNG PHÁP ĐỀ XUẤT

A. Quy trình huấn luyện 2 giai đoạn

Để tối ưu hóa biểu diễn dữ liệu và giải quyết chênh lệch phân phối, chúng tôi đề xuất quy trình huấn luyện 2 giai đoạn (*2-Stage Pipeline*) kết hợp dán nhãn giả (*Pseudo-labeling*) [3] như trên Hình 1:

- **Giai đoạn 1 (*Single-task Pre-training và Pseudo-labeling*):** Phân rã bài toán thành 6 mô hình phân loại độc lập. Sau khi hội tụ trên tập Train, mô hình suy luận trên tập Test để tạo nhãn giả. Dữ liệu Test mang nhãn giả được hợp nhất trở lại tập Train, hình thành kho dữ liệu mở rộng (*Augmented Dataset*).
- **Giai đoạn 2 (*Multi-task Training*):** Khai thác kho dữ liệu mở rộng để huấn luyện các kiến trúc đa nhiệm tối ưu hóa đồng thời 6 đầu ra. Việc tiếp xúc trước với không gian đặc trưng của tập Test giúp triệt tiêu dịch chuyển phân phối, gia tăng độ chính xác và tính ổn định.

B. Hàm mất mát tùy chỉnh

Thước đo Exact-Match đánh giá tính chính xác đồng thời cả 6 thuộc tính. Việc chỉ tối thiểu hóa sai số trung bình là rủi ro lớn, dễ khiến mô hình phớt lờ thuộc tính khó để ưu tiên sự hội tụ ở các thuộc tính dễ. Nhằm giải quyết lỗ hổng này, chúng tôi thiết kế hàm *Max-Penalty Loss*, tích hợp sai số trung bình và sai số cực đại:

$$\mathcal{L}_{total} = \frac{1}{K}\sum_{i=1}^{K}\mathcal{L}_i + \alpha \max_{i\in\{1..K\}}(\mathcal{L}_i) \tag{1}$$

Trong đó, $K = 6$ là số lượng thuộc tính, $\mathcal{L}_i$ là Cross-Entropy Loss của thuộc tính i, và α là hệ số điều chuẩn (*penalty weight*). Cơ chế này tạo lực chú ý mang tính cưỡng chế, ép hệ thống dồn tài nguyên cập nhật trọng số vào đầu ra có sai số cao nhất, duy trì tốc độ hội tụ đồng đều.

C. Nhóm mô hình Temporal Actions Network

Cốt lõi thuật toán của **TAGFlow** là hệ sinh thái các mô hình chuyên trách xử lý dữ liệu chuỗi biến thiên. Nhằm trích xuất biểu diễn đặc trưng hiệu quả, chúng tôi thiết kế cơ chế *AttentionPooling1D*. Thay vì dùng Global Average Pooling dễ gây loãng thông tin, *AttentionPooling1D* áp dụng lớp tuyến tính để tính trọng số tầm quan trọng (*attention scores*) cho từng mốc thời gian. Các vị trí đệm (*padding*) được xử lý bằng *Masked Fill* với giá trị âm vô cùng. Kết quả là vector biểu diễn tinh gọn cung cấp cho 6 khối phân loại (*Classifier Heads*). Hệ sinh thái bao gồm bốn kiến trúc:

1) TAGNet (Temporal Actions Graph Network): Đóng vai trò là kiến trúc chủ lực (flagship model), **TAGNet** tiếp cận chuỗi hành vi dưới lăng kính Mạng nơ-ron Đồ thị (*Graph Neural Network*). Điểm vượt trội cốt lõi của TAGNet nằm ở khả năng mở rộng (*Scalability*) và tính giải thích (*Explainability - xAI*). Mô hình hóa mỗi hành động

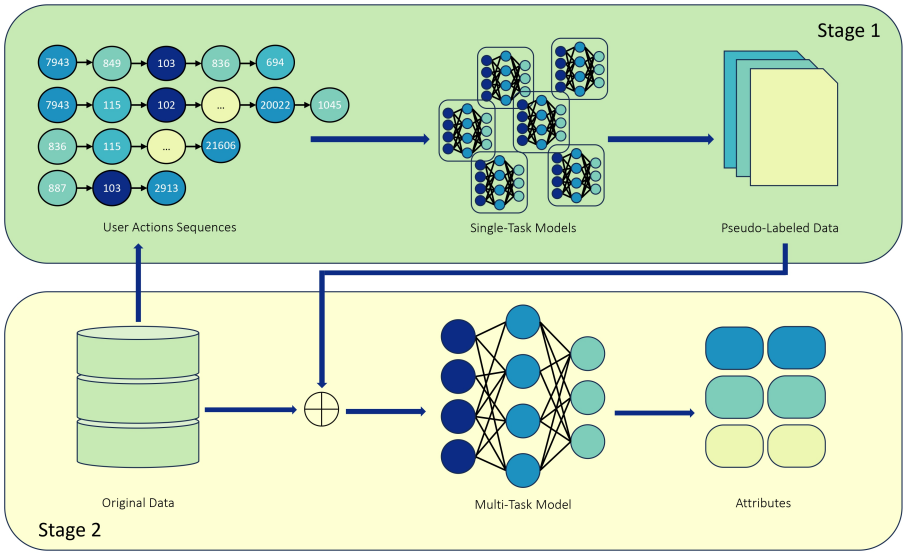

Hình 1: Quy trình huấn luyện 2 giai đoạn của hệ thống TAGFlow

như một đỉnh và mối liên hệ thời gian như cạnh giúp truy vết logic ra quyết định dễ dàng.

- **Đồ thị có hướng:** Kết hợp tham số cửa sổ và độ giãn cách, mô hình tự động thiết lập hai ma trận kề: hướng về quá khứ (`adj_past`) và tương lai (`adj_future`).
- **Truyền tin đa hướng:** Dữ liệu tổng hợp từ hai chiều thời gian sinh ra các biểu diễn ẩn giàu ngữ cảnh, lập bản đồ xuất sắc các tương tác phi tuyến.

2) Các kiến trúc bổ trợ (TAANet, TARNet, TACNet): Nhằm đa dạng hóa không gian giả thuyết và củng cố độ vững chắc của hệ thống, chúng tôi phát triển ba biến thể bổ trợ:

- **TAANet (Attention Network):** Mô hình ứng dụng *Transformer Encoder* đa đầu kết hợp với Positional Encoding [4], nắm bắt tốt ngữ cảnh toàn cục của chuỗi dài.
- **TARNet (Recurrent Network):** Khai thác cơ chế bộ nhớ ngắn hạn có cổng (GRU/LSTM), xuất sắc trong việc duy trì tính tuần tự nhân quả của dòng sự kiện theo trục thời gian tuyến tính.
- **TACNet (Convolutional Network):** Triển khai khối *ModernTCN* [5] với *Depthwise Separable Convolution*, tối ưu hóa trích xuất đặc trưng cục bộ với chi phí tính toán cực thấp.

Sự hội tụ của bốn kiến trúc này không chỉ tạo nền tảng vững chắc cho kỹ thuật học kết hợp (*Ensemble Learning*), mà còn cung cấp tính linh hoạt cao để triển khai giải pháp vào các môi trường doanh nghiệp có giới hạn phần cứng đa dạng.

V. KẾT QUẢ THỰC NGHIỆM

A. Thiết lập thực nghiệm

Thực nghiệm được tiến hành trên môi trường Kaggle (NVIDIA Tesla T4 GPU) với `RANDOM_SEED` $= 42$ (đảm bảo tính công bằng và khả năng tái lập).

Mạng nơ-ron được tối ưu bằng **AdamW** [6] với *learning rate* $lr = 10^{-3}$ và *weight decay* 10^{-2}. Chúng tôi tích hợp lịch trình **OneCycleLR** [7] (`pct_start` $= 0.1$, suy giảm cosine) với tỷ lệ phân chia khởi đầu và kết thúc lần lượt là 25.0 và 1000.0 để đẩy nhanh tốc độ hội tụ.

Trọng số lớp nghịch đảo (*inverse class weights*) được làm mượt bằng hàm căn bậc hai và giới hạn tối đa ở mức 10.0 để xử lý mất cân bằng lớp. Kết hợp với *Label Smoothing* [8] ($\epsilon = 0.01$) giúp mô hình bớt tự tin thái quá vào nhãn nhiễu. Hệ số điều chuẩn Giai đoạn 2 cho hàm *Max-Penalty Loss* được thiết lập ở mức $\alpha = 2.0$.

Quá trình huấn luyện sử dụng *batch size* 256 và không gian nhúng 256, khởi tạo trước bằng ma trận trọng số *Word2Vec* [9]. Giai đoạn 1 huấn luyện tối đa 50 epochs (dừng sớm 8 epochs). Giai đoạn 2 huấn luyện tối đa 150 epochs (dừng sớm 15 epochs).

B. Các mô hình cơ sở

Để làm nổi bật tính ưu việt của hệ thống TAGFlow, chúng tôi tiến hành đối chiếu với hai nhóm mô hình cơ sở:

- **Mô hình học máy truyền thống:** Bao gồm Random Forest [10], Support Vector Machine [11], XGBoost [12], LightGBM [13] (trích xuất đặc trưng bằng Mean Pooling Word2Vec). Nhóm mô hình này gặp hạn chế trong việc nắm bắt các phụ thuộc tuần tự thời gian.
- **Mạng nơ-ron hồi quy cơ bản:** Bao gồm RNN, LSTM [14], GRU [15] với cấu hình lớp ẩn 256, 2 lớp xếp chồng (`num_layers` $= 2$) tương đồng với cấu hình của TARNet để đảm bảo tính công bằng khi so sánh.

C. Chỉ số đánh giá

Theo quy định của cuộc thi, chỉ số **Exact-Match Accuracy** (Độ chính xác khớp tuyệt đối) trên tập Test được sử dụng làm thước đo xếp hạng chính. Thêm vào đó, **Macro F1-Score** cho từng thuộc tính riêng lẻ được theo dõi nhằm phục vụ cho quá trình phân tích toàn diện (*Holistic Evaluation*).

Bảng II: Bảng so sánh hiệu năng các mô hình.

Mô hình	**F1 Attr 1** (↑)	**F1 Attr 2** (↑)	**F1 Attr 3** (↑)	**F1 Attr 4** (↑)	**F1 Attr 5** (↑)	**F1 Attr 6** (↑)	**Val EM** (↑)
Mô hình học máy truyền thống							
Random Forest	0.4890	0.1049	0.0379	0.4670	0.1056	0.0371	0.0003
SVM	0.4561	0.0983	0.0338	0.4334	0.0936	0.0321	0.0003
XGBoost	0.4989	0.1422	0.0511	0.5036	0.1278	0.0499	0.0010
LightGBM	0.4515	0.1313	0.0138	0.4740	0.1198	0.0150	0.0000
Mạng nơ-ron hồi quy cơ bản							
RNN*	0.7997	0.5445	0.0696	0.7512	0.3001	0.0095	0.0014
LSTM*	0.9604	0.9582	0.0496	0.8125	0.7537	0.0076	0.0011
GRU*	0.8948	0.9759	0.3482	0.8702	0.8770	0.0486	0.0238
Mô hình đề xuất (Ours)							
TAANet*	**1.0000**	0.9994	0.9980	0.9927	**0.9994**	**0.9992**	0.9967
TACNet*	**1.0000**	0.9999	0.9982	**0.9972**	0.9993	0.9991	0.9969
TARNet*	**1.0000**	**1.0000**	**0.9987**	0.9945	0.9993	0.9989	**0.9974**
TAGNet*	**1.0000**	**1.0000**	0.9979	**0.9972**	0.9993	**0.9992**	0.9969

So sánh toàn cục: **Hạng 1**, Hạng 2

** Kết quả được báo cáo là mô hình có hiệu suất tốt nhất được chọn ra từ nhiều lượt huấn luyện độc lập. Vui lòng tham khảo Phụ lục D để biết chi tiết.*

D. Kết quả tổng thể

Dựa trên Bảng II, chúng tôi rút ra ba kết luận quan trọng:

- **Sự thất bại của mô hình học máy truyền thống:** Random Forest, SVM hay LightGBM gần như tê liệt với chỉ số Exact-Match xấp xỉ 0.0000. Mặc dù các mô hình có thể nắm bắt tần suất hành vi, chúng lại không hiểu rõ bản chất trục thời gian. Điều này chứng minh việc dự báo phụ thuộc rất lớn vào tính thứ tự trước-sau và các luồng nhân quả thay vì sự hiện diện đơn thuần.
- **Giới hạn của mạng hồi quy cơ bản:** Mặc dù GRU đạt kết quả F1 khá tốt ở một số thuộc tính (Attr 2: 0.9759), nhưng Val EM lại tụt xuống mức 0.0238. Nghịch lý này minh chứng cho độ khó cực đại của thước đo Exact-Match: sai 1 thuộc tính là toàn bộ chuỗi bị đánh giá sai. Mạng hồi quy truyền thống thiếu cơ chế chia sẻ biểu diễn đa nhiệm dẫn đến hội tụ lệch pha.
- **Sự vượt trội toàn diện của TAGFlow:** Bốn kiến trúc đề xuất thiết lập khoảng cách biệt lập so với phần còn lại, đẩy Val EM lên mức > 0.9960. Sự thành công này là kết quả cộng hưởng từ *AttentionPooling1D* kết hợp cùng *Max-Penalty Loss*, giúp dồn lực học hỏi các thuộc tính khó.

Để đánh giá khả năng tổng quát hóa (*generalization*), chúng tôi đối chiếu hiệu năng giữa tập Validation và tập Public Test trên Bảng III. TAGNet thể hiện tính ổn định đáng kinh ngạc khi độ suy giảm hiệu suất (*performance drop*) giữa Val và Public Test rất thấp ($0.9969 \rightarrow 0.9725$).

Bảng III: So sánh kết quả giữa tập Validation và Public Test

Mô hình	**Val EM** (↑)	**Public Test EM** (↑)
TAANet (Attention)	0.9967	0.9579
TACNet (Convolutional)	0.9969	0.9735
TARNet (Recurrent)	0.9974	0.9746
TAGNet (Graph)	0.9969	0.9725

E. Nghiên cứu cắt bỏ

Để chứng minh tính cấp thiết của quy trình huấn luyện 2 giai đoạn và hàm mất mát tùy chỉnh, một thực nghiệm cắt bỏ đã được tiến hành trên kiến trúc chủ lực TAGNet. Kết quả đối chiếu được trình bày chi tiết tại Bảng IV.

Bảng IV: Đánh giá tác động của quy trình 2 giai đoạn và hàm mất mát

Thiết lập mô hình TAGNet	**Val EM** (↑)	**Public Test EM** (↑)
TAGNet (Đề xuất gốc)	**0.9969**	**0.9725**
TAGNet (*w/o Stage 1*)	0.9942	0.9066
TAGNet (*w/o Stage 2*)	0.9972	0.9654
TAGNet (*w/o Max-Penalty Loss*)	0.9947	0.9125

Phân tích sự suy giảm hiệu suất từ các thiết lập cắt bỏ, chúng tôi rút ra ba luận điểm quan trọng:

- **Tác động của Giai đoạn 1:** Khi loại bỏ Giai đoạn 1 (*w/o Stage 1*), mô hình phải huấn luyện trực tiếp trên tập dữ liệu gốc mà không được tiếp xúc trước với không gian đặc trưng của tập Test. Hậu quả là Public Test EM sụt giảm nghiêm trọng từ 0.9725 xuống chỉ còn 0.9066. Điều này minh chứng cho vai trò tối quan trọng của Giai đoạn 1 trong việc chống lại sự dịch chuyển phân phối (*distribution shift*) và giúp mô hình thích ứng nhanh với các luồng hành vi mới lạ.
- **Tác động của Giai đoạn 2:** Khi loại bỏ Giai đoạn 2 (*w/o Stage 2*) và sử dụng 6 mô hình TAGNet đơn nhiệm độc lập để ghép lại kết quả, Val EM tăng nhẹ (lên 0.9972) nhưng Public Test EM lại sụt giảm (xuống 0.9654). Nghịch lý này thể hiện việc các mô hình đơn nhiệm đã bị quá khớp (*overfitting*) cục bộ. Khi không chia sẻ không gian ẩn (*latent space*), các mô hình mất đi khả năng đối chiếu logic chéo giữa các thuộc tính (ví dụ: quán tính ngành hàng), dẫn đến các dự báo mâu thuẫn và thiếu nhất quán trên dữ liệu thực tế.
- **Tác động của Max-Penalty Loss:** Khi thay thế hàm mất mát tùy chỉnh bằng hàm Cross-Entropy trung bình thông thường, Public Test EM rơi xuống mức 0.9125. Không có lực chú ý mang tính cưỡng chế, mạng nơ-ron có xu hướng "lười biếng", chỉ tập trung tối ưu các nhãn dễ đoán (Entropy thấp) và phớt lờ các nhãn khó. Vì thước đo Exact-Match yêu cầu đúng tuyệt đối cả 6 thuộc tính, sự xao nhãng ở dù chỉ một nhãn khó cũng đủ khiến toàn bộ dự đoán của chuỗi bị đánh giá sai.

Quy trình 2 giai đoạn và hàm suy hao tùy chỉnh không chỉ là những thủ thuật tối ưu rời rạc, mà chính là bản lề cấu trúc giúp hệ thống TAGFlow đạt được sự dung hòa hoàn hảo giữa khả năng tổng quát hóa và tính nhất quán tuyệt đối trong suy luận đa biến.

F. Khả năng giải thích của mô hình

Một trong những ưu điểm vượt trội của kiến trúc chủ lực **TAGNet** so với các mô hình "hộp đen" (*black-box*) truyền thống là khả năng giải thích được logic ra quyết định. Thông qua việc bóc tách các ma trận trọng số nội tại, chúng tôi tiến hành hai phân tích chuyên sâu nhằm chứng minh hệ thống thực sự thấu hiểu nghiệp vụ thay vì học vẹt các mẫu thống kê.

1) Đồ thị nhân quả: Bằng cách trích xuất trọng số cạnh từ cơ chế truyền tin của Mạng nơ-ron Đồ thị (GNN), chúng tôi tái lập được mạng lưới luồng hành vi mà mô hình tự động học được (Hình 2).

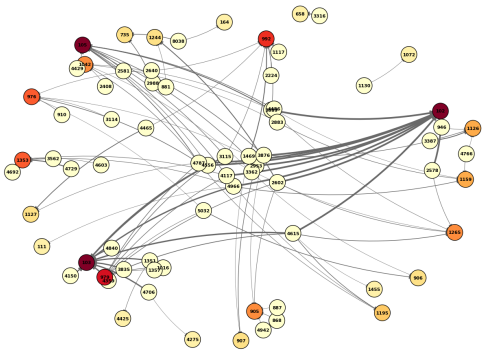

Hình 2: Mạng lưới nhân quả với 100 luồng hành vi trọng yếu được trích xuất từ trọng số của TAGNet.

Kết quả trực quan hóa cho thấy sự hình thành của một cấu trúc "phễu hội tụ". Hàng loạt các hành động khởi đầu khác nhau đều trỏ mũi tên với sức mạnh kết nối cực lớn (trọng số chú ý $> 80\%$) về một số đỉnh cụ thể, điển hình là mã hành động `102`. Điều này hoàn toàn khớp với phân

tích nghiệp vụ ban đầu: `102` đóng vai trò là "nút thắt" điều hướng (ví dụ: Xem giỏ hàng, Xác nhận thanh toán) mà mọi người dùng đều phải đi qua. Việc TAGNet tự động nhận diện và cấp trọng số cao cho các nút thắt này chứng minh mô hình đã nắm bắt được "topo học" của luồng khách hàng. Chi tiết hơn có thể xem tại Phụ lục E.

2) Phân tích bẫy "Ảo tưởng": Để tìm hiểu nguyên nhân tại sao hệ thống đôi khi vẫn dự báo sai, chúng tôi tiến hành phân tách và đối chiếu sự phân bổ trọng số chú ý (*Attention Weights*) giữa hai nhóm dự đoán: Đúng và Sai.

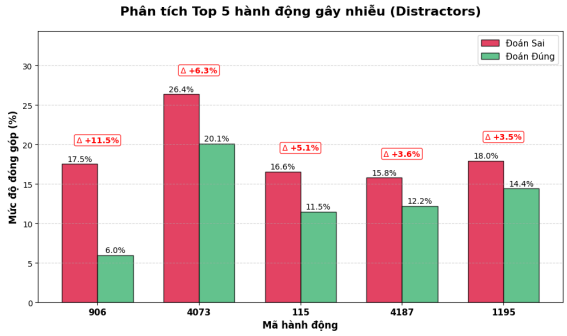

Hình 3: Biểu đồ đối chiếu mức độ tập trung Attention vào các hành động gây nhiễu giữa nhóm dự đoán Sai và Đúng trên thuộc tính 3.

Như được trình bày tại Hình 3, phân tích đã vạch trần các mã hành động đóng vai trò là "cú lừa" (*Distractors*). Lấy ví dụ mã `4073` hoặc `906`, khi mô hình đưa ra dự đoán sai, nó đã dồn sự tập trung một cách bất thường vào các nút này. Đây có thể là các hành vi mang tính chất "nhiễu" (như khách hàng vô tình nhấp chuột hoặc xem sản phẩm không liên quan).

Khi mô hình lỡ dồn quá nhiều Attention vào đây, nó sẽ bị mất đi bối cảnh toàn cục và dẫn đến hiện tượng "ảo tưởng" (tin rằng đây là tín hiệu mua hàng chính). Phân tích diện rộng về hiện tượng này trên các thuộc tính khác được trình bày chi tiết tại Phụ lục F.

G. Khả năng mở rộng

Bên cạnh độ chính xác, khả năng mở rộng và triển khai thực tế (*Deployment Scalability*) là tiêu chí sống còn, đặc biệt khi hệ thống phải xử lý hàng triệu luồng dữ liệu khách hàng trong môi trường thương mại điện tử thực tế. Hệ sinh thái TAGFlow được thiết kế với triết lý tinh gọn và tối ưu hóa tài nguyên từ tầng lõi, thể hiện qua hai khía cạnh trọng yếu:

- **Tốc độ suy luận và Tối ưu tính toán:** Để giải quyết bài toán chuỗi có độ dài biến thiên (*variable-length sequences*), hệ thống loại bỏ hoàn toàn các vòng lặp tuần tự tốn kém. Thay vào đó, TAGNet áp dụng cơ chế *Masked Fill* kết hợp xử lý đồ thị theo lô (*Batched Graph Processing*). Kỹ thuật này cho phép tính toán song song các phép toán ma trận trên GPU. Hơn nữa, với kiến trúc đa nhiệm, hệ thống dự đoán đồng thời 6 nhãn chỉ trong một lượt truyền tiến (*Forward Pass*), loại bỏ hoàn toàn độ trễ giao tiếp (*Zero-Latency Bottleneck*), sẵn sàng đáp ứng lưu lượng truy cập khổng lồ trong thời gian thực.
- **Khả năng mở rộng linh hoạt:** Điểm khác biệt mang tính chiến lược của kiến trúc TAGNet nằm ở việc mô hình hóa chuỗi hành động dưới dạng đồ thị có hướng. Thay vì bị giới hạn bởi cấu trúc chuỗi cứng nhắc, việc biểu diễn hành vi thành các đỉnh (nodes) và luồng di chuyển thành các cạnh (edges) mang lại khả năng mở rộng gần như không giới hạn về mặt nghiệp vụ. Trong tương lai, khi doanh nghiệp tích hợp thêm các tính năng mới vào ứng dụng (tương ứng với các tập mã hành động mới), mạng nơ-ron đồ thị (GNN) có thể dễ dàng tiếp nhận, mở rộng ma trận kề (`adj_past`, `adj_future`) và lập bản đồ các hành vi này một cách tự nhiên mà không đòi hỏi phải thiết kế lại toàn bộ kiến trúc lõi.

Đánh giá trên khẳng định rằng hệ thống TAGFlow không chỉ xuất sắc vượt qua các bài kiểm tra về độ chính xác (Exact-Match) mà còn hoàn toàn đáp ứng các tiêu chuẩn khắt khe về hiệu năng, mang tính kế thừa cao và sẵn sàng thương mại hóa (*Production-ready*) ở quy mô lớn.

VI. KẾT LUẬN

Bài báo cáo này trình bày **TAGFlow**, một hệ thống đa nhiệm được thiết kế chuyên biệt để giải quyết bài toán dự báo hành vi người dùng có độ dài biến thiên trong thương mại điện tử. Bằng việc kết hợp quy trình huấn luyện hai giai đoạn, hàm mất mát tùy chỉnh *Max-Penalty*, và kiến trúc chủ lực **TAGNet** dựa trên Mạng nơ-ron Đồ thị (GNN), hệ thống đã khắc phục hiện tượng dịch chuyển phân phối và tối ưu hóa xuất sắc thước đo Exact-Match.

Từ những thấu hiểu sâu sắc về dữ liệu, chúng tôi cũng cụ thể hóa giá trị của mô hình thành ba trụ cột hành động đề xuất doanh nghiệp thực thi nhằm tối ưu hóa vận hành:

- **Tối ưu vị trí kho bãi chủ động:** Dựa trên khả năng dự báo chính xác 6 thuộc tính, đặc biệt là nhóm hàng thiết yếu (FMCG) có độ phân tán thấp, hệ thống cung cấp căn cứ để phân bổ hàng hóa sát với "điểm nóng"nhu cầu tại từng trung tâm phân phối, từ đó rút ngắn đáng kể thời gian đóng gói và giao hàng.
- **Hệ thống cảnh báo chuỗi cung ứng:** Cung cấp luồng tín hiệu tự động và theo thời gian thực cho bộ phận vận hành và thu mua. Giá trị cốt lõi là giúp doanh nghiệp chủ động điều phối luồng hàng ngay khi phát hiện cụm nhu cầu đột biến, tránh đứt gãy hàng hóa hoặc rủi ro tồn kho tiêu cực.
- **Chiến lược Sales và Marketing cá nhân hóa:** Tận dụng các nút thắt điều hướng trọng yếu (như mã `102`, `105`) được phát hiện từ đồ thị nhân quả và hành vi khoanh vùng của người dùng, bộ phận Marketing có thể kích hoạt các chiến dịch gợi ý chéo (*Cross-sell*) sản phẩm bổ trợ cùng ngành hàng ngay tại thời điểm khách hàng đang cân nhắc, giúp đẩy nhanh quá trình ra quyết định và tối đa hóa tỷ lệ chốt đơn.

Kết quả thực nghiệm đã khẳng định sự vượt trội toàn diện của TAGFlow, đồng thời minh chứng tính minh bạch của mô hình thông qua khả năng giải thích từ (*xAI*). Những đóng góp này giải quyết trọn vẹn thách thức kỹ thuật của cuộc thi DataFlow 2026, đồng thời cung cấp một công cụ chiến lược mạnh mẽ trong thực tiễn.

Để đưa TAGFlow vào môi trường thương mại hóa ở quy mô lớn, chúng tôi đề xuất lộ trình phát triển chia thành 3 giai đoạn trọng điểm:

- **Giai đoạn 1 - Chuyển đổi suy luận thời gian thực:** Đưa mô hình TAGNet từ môi trường tĩnh (offline

batch) lên nền tảng xử lý luồng Apache Kafka. Để duy trì sức mạnh của chiến lược dán nhãn giả (*Pseudo-labeling*) trong môi trường thực tế, hệ thống sẽ chuyển sang cơ chế học bán giám sát trực tuyến: tự động thu thập các dự báo có độ tự tin cao trong ngày làm dữ liệu tinh chỉnh (fine-tune) cho ca đêm. Đồng thời, kết hợp song song cơ chế *Rule-based fallback* để chốt đơn tức thì với nhóm khách hàng lướt nhanh (≤ 5 bước).

- **Giai đoạn 2 - Nâng cấp và phát triển mô hình:** Tích hợp MLOps và thiết lập cơ chế học liên tục với vòng lặp phản hồi tự động. Sự nâng cấp này đảm bảo trọng số mạng nơ-ron liên tục tự cập nhật, thích ứng nhạy bén với các chiến dịch flash sale hoặc xu hướng tiêu dùng mới mà không tiêu tốn tài nguyên huấn luyện lại.
- **Giai đoạn 3 - Mở rộng ứng dụng sinh thái:** Nâng cấp đồ thị TAGNet để kết nối thêm các chiều dữ liệu mới (nhân khẩu học, lịch sử mua hàng dài hạn), biến TAGFlow từ một công cụ dự báo phiên giao dịch đơn lẻ thành bộ não điều phối toàn diện hệ sinh thái thương mại điện tử của doanh nghiệp.

TÀI LIỆU THAM KHẢO

[1] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *International Conference on Learning Representations (ICLR)*, 2017.

[2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 2019, pp. 4171–4186.

[3] D.-H. Lee, "Pseudo-label: The simple and efficient semi-supervised learning method for deep neural networks," in *Workshop on challenges in representation learning, ICML*, vol. 3, no. 2, 2013, p. 896.

[4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in neural information processing systems*, vol. 30, 2017.

[5] D. Luo, X. Wang, et al., "ModernTCN: A Modern Pure Convolutional Structure for Time Series Analysis," in *International Conference on Learning Representations (ICLR)*, 2024.

[6] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations (ICLR)*, 2019.

[7] L. N. Smith and N. Topin, "Super-convergence: Very fast training of neural networks using large learning rates," in *Artificial intelligence and machine learning for multi-domain operations applications*, vol. 11006. SPIE, 2019, p. 1100612.

[8] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the inception architecture for computer vision," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2016, pp. 2818–2826.

[9] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," *arXiv preprint arXiv:1301.3781*, 2013.

[10] L. Breiman, "Random forests," *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001.

[11] C. Cortes and V. Vapnik, "Support-vector networks," *Machine learning*, vol. 20, no. 3, pp. 273–297, 1995.

[12] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining*, 2016, pp. 785–794.

[13] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in neural information processing systems*, vol. 30, 2017.

[14] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural computation*, vol. 9, no. 8, pp. 1735–1780, 1997.

[15] K. Cho, B. Van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using RNN encoder-decoder for statistical machine translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014, pp. 1724–1734.

PHỤ LỤC

A. *Phân tích kỹ thuật các hành vi chuỗi*

Trong phần này, chúng tôi trình bày các bằng chứng định lượng về luồng di chuyển của người dùng, làm cơ sở cho việc thiết kế kiến trúc.

1) Ma trận xác suất chuyển đổi hành vi: Phân tích ma trận chuyển đổi giúp xác định các luồng chảy chính trong ứng dụng. Một số cặp hành động có xác suất chuyển tiếp xấp xỉ 100% (ví dụ: $10477 \rightarrow 697$ hoặc $2207 \rightarrow 8615$), chứng tỏ đây là các quy trình kỹ thuật bắt buộc của hệ thống.

Đặc biệt, dữ liệu chỉ ra mã 8615 đóng vai trò là ngưỡng khám phá của ứng dụng. Trước 8615, khách hàng ở trạng thái nạp dữ liệu (load trang). Ngay sau khi vượt qua bước đệm 8615, người dùng tỏa ra nhiều hướng khác nhau (chỉ $\sim 33\%$ chuyển sang mã lướt tiếp 105). Điều này khẳng định thời điểm ngay sau mã 8615 là thời điểm vàng lý tưởng nhất để hệ thống recommendation hoặc marketing can thiệp vào luồng của người dùng.

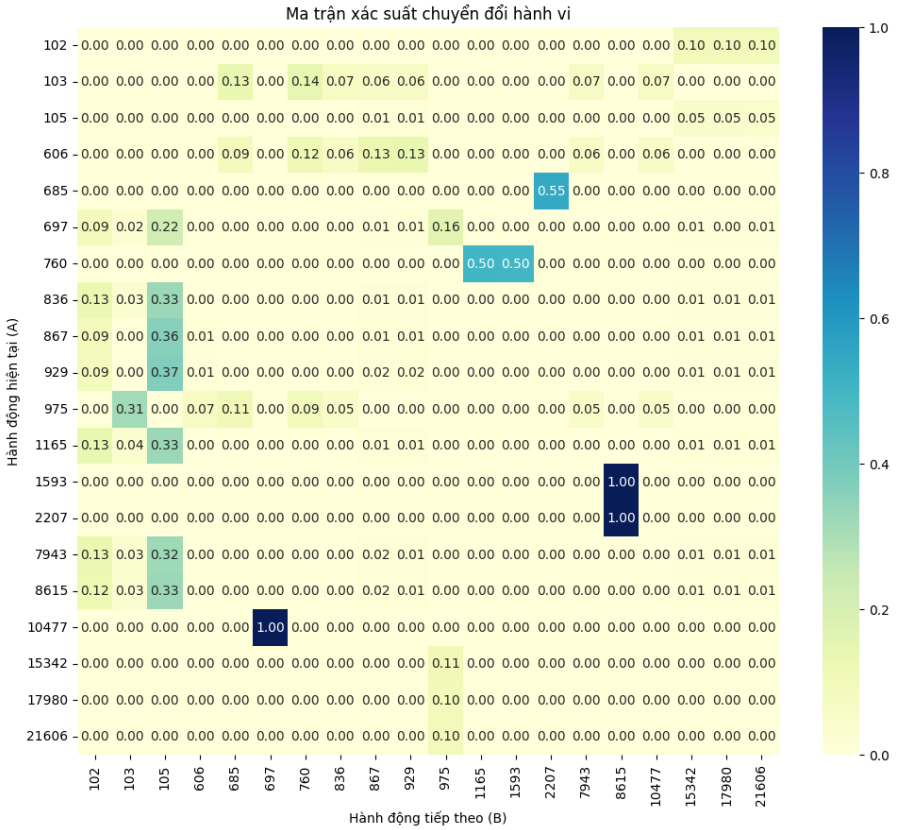

Hình 4: Ma trận xác suất chuyển đổi giữa các mã hành động phổ biến

2) Các cụm hành động phổ biến: Chúng tôi ghi nhận các luồng phổ biến nhất của người dùng thông qua Bigram và Trigram:

Bảng V: Top 10 cụm 2 hành động liên tiếp phổ biến nhất

STT	Cụm hành động (Pattern)	Tần suất (Lần)
1	(760, 1165)	9331
2	(10477, 697)	9256
3	(685, 2207)	9241
4	(2207, 8615)	9223
5	(760, 1593)	9188
6	(1593, 8615)	9173
7	(685, 1464)	7700
8	(8615, 105)	6026
9	(24438, 697)	4442
10	(102, 17980)	4056

- Top Bigrams: Cặp $(760, 1165)$ và $(10477, 697)$ xuất hiện với tần suất cao nhất, đại diện cho các hành vi mở đầu tiêu chuẩn.
- Top Trigrams: Các luồng $(685 \rightarrow 2207 \rightarrow 8615)$ và $(760 \rightarrow 1593 \rightarrow 8615)$ cho thấy sự hội tụ về các trang chức năng cốt lõi trước khi người dùng thực hiện các hành động chuyên sâu hơn.

Bảng VI: Top 10 cụm 3 hành động liên tiếp phổ biến nhất

STT	Cụm hành động (Pattern)	Tần suất (Lần)
1	(685, 2207, 8615)	9223
2	(760, 1593, 8615)	9173
3	(760, 1165, 105)	3053
4	(2207, 8615, 105)	3033
5	(10477, 697, 105)	2994
6	(1593, 8615, 105)	2993
7	(685, 1464, 105)	2605
8	(24438, 697, 1068)	2247
9	(697, 1068, 5289)	2247
10	(7362, 2621, 166)	2246

B. Đặc trưng thống kê và độ phức tạp của nhãn

1) Phân phối và Entropy của các thuộc tính: Phân tích Entropy cho thấy sự phân cấp khác biệt rõ rệt về độ khó dự báo giữa 3 nhóm thuộc tính:

Bảng VII: Chỉ số Entropy của các thuộc tính đầu ra

Thuộc tính	Chỉ số Entropy
`attr_1`	1.7338
`attr_4`	1.7274
`attr_2`	3.0431
`attr_5`	3.0468
`attr_3`	4.5943
`attr_6`	4.5942

- Nhóm Entropy thấp (`attr_1, attr_4`): Giá trị ~ 1.73, cho thấy tính tập trung cao, đại diện cho cấu trúc 12 Ngành hàng lớn.
- Nhóm Entropy trung bình (`attr_2, attr_5`): Giá trị ~ 3.04, đại diện cho 31 Danh mục sản phẩm trung gian.
- Nhóm Entropy cao (`attr_3, attr_6`): Giá trị ~ 4.59, phản ánh sự phân tán cực lớn của 99 nhãn thương hiệu/mã chi tiết, đòi hỏi mô hình phải có khả năng trích xuất đặc trưng tinh vi.

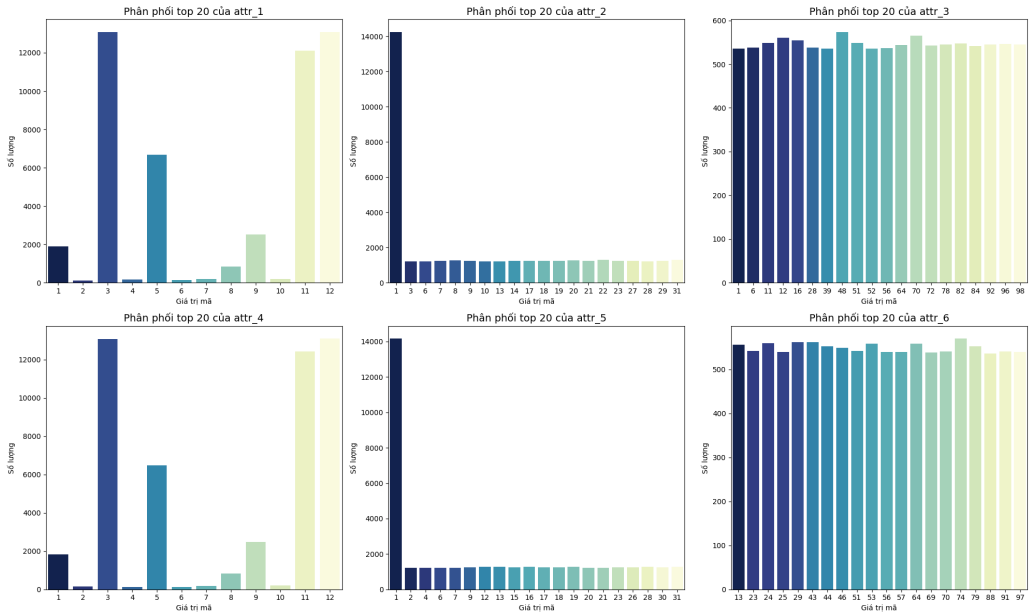

Hình 5: Thống kê mô tả và phân phối tần suất của 6 biến mục tiêu.

2) Kiểm định giả thuyết loại trừ: Chúng tôi đã thực hiện kiểm định giả thuyết xem các cặp (`attr_1`, `attr_2`) và (`attr_4`, `attr_5`) có phải là định dạng Tháng - Ngày hay không. Kết quả ghi nhận 348 và 398 lỗi logic (ví dụ: ngày 30, 31 trong tháng 2), từ đó bác bỏ giả thuyết dữ liệu thời gian và khẳng định tính chất phân cấp danh mục.

3) Tương quan đa nhiệm và trùng khớp nhãn: Phân tích Cramer's V giúp định lượng mối quan hệ giữa 6 đầu ra, phục vụ cho việc tối ưu hóa cấu trúc Multi-task Learning.

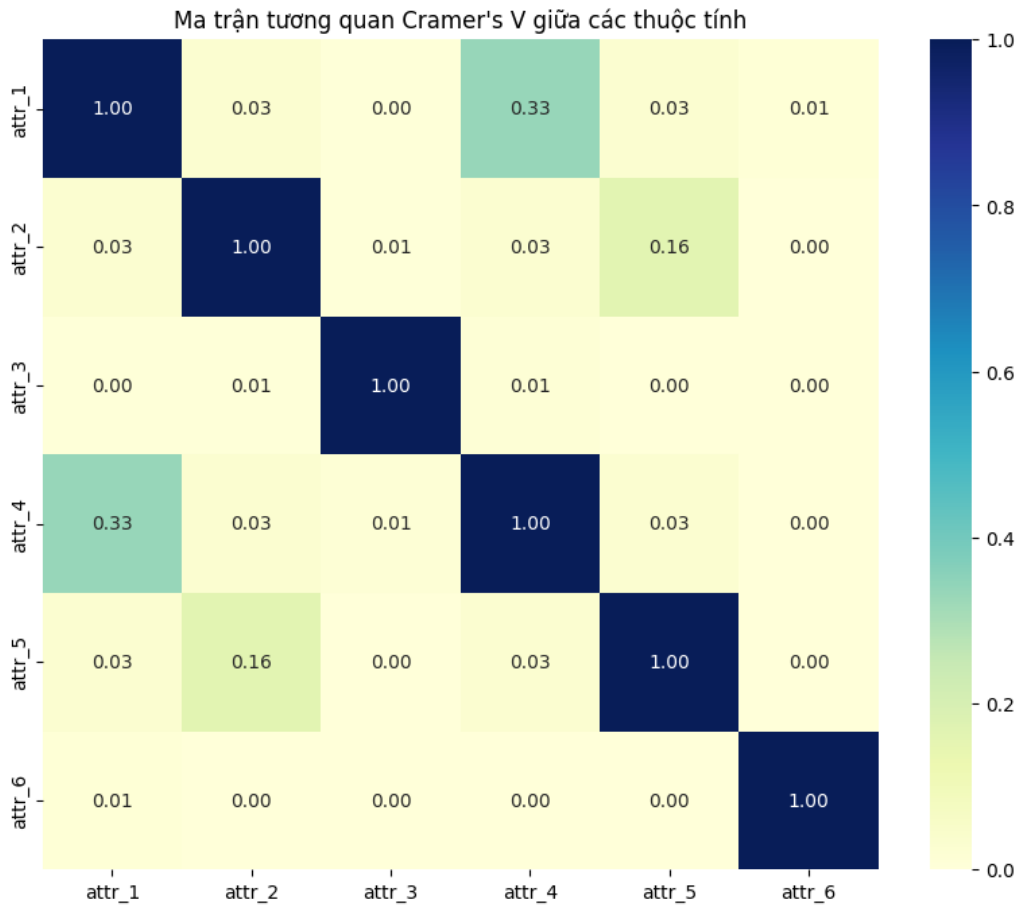

Hình 6: Ma trận tương quan Cramer's V thể hiện mối liên hệ giữa các thuộc tính đầu ra.

Việc chỉ số tương quan giữa các cặp chéo (1-4, 2-5) cao hơn hẳn các cặp khác đã củng cố quyết định thiết kế mô hình theo hướng dự báo song song hai nhóm sản phẩm bổ trợ trong cùng một phiên giao dịch.

Để kiểm chứng bản chất của sự tương quan trên, chúng tôi tiếp tục đo lường độ lệch giá trị giữa các cặp thuộc tính cấp cao của hai sản phẩm: (`attr_1-attr_4`) và (`attr_2-attr_5`).

Kết quả cho thấy:

- Cấp độ ngành hàng lớn (1-4): Tỷ lệ chênh lệch bằng 0 (trùng khớp hoàn toàn) chiếm $25,13\%$.
- Cấp độ danh mục trung (2-5): Tỷ lệ chênh lệch bằng 0 chiếm $27,82\%$.

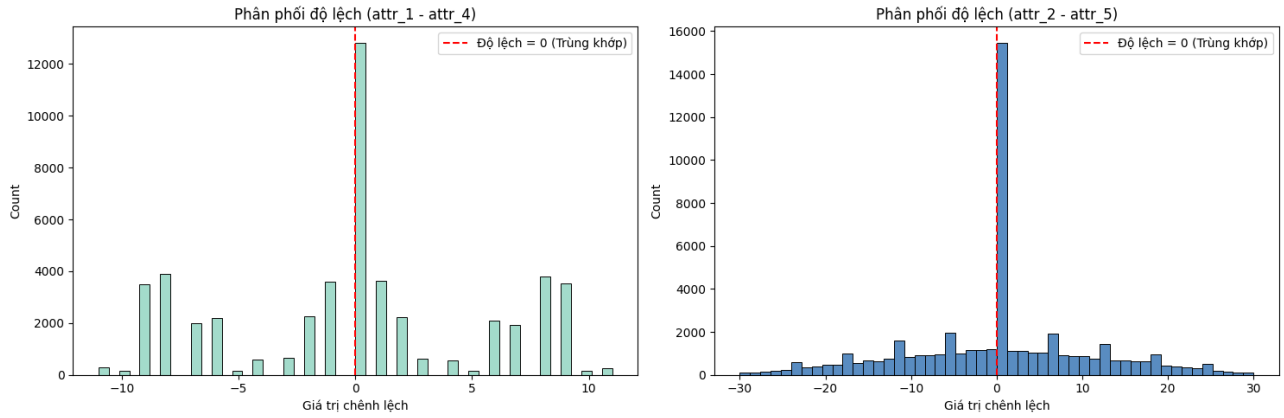

Hình 7: Phân phối độ lệch giữa cặp thuộc tính (1-4) và (2-5)

Phân phối của cả hai phép trừ đều tạo thành một đỉnh cực kỳ nhọn và áp đảo tại giá trị 0. Bằng chứng định lượng này một lần nữa khẳng định giả thuyết quan trọng: Sự tương quan mạnh giữa các nhãn không đến từ một quy luật chuyển đổi

chéo phức tạp nào, mà thực chất đến từ việc khách hàng có xu hướng giữ nguyên danh mục, liên tục xem xét các sản phẩm thay thế trong cùng một phân khúc ở mỗi phiên giao dịch.

C. Sự dịch chuyển phân phối đầu vào

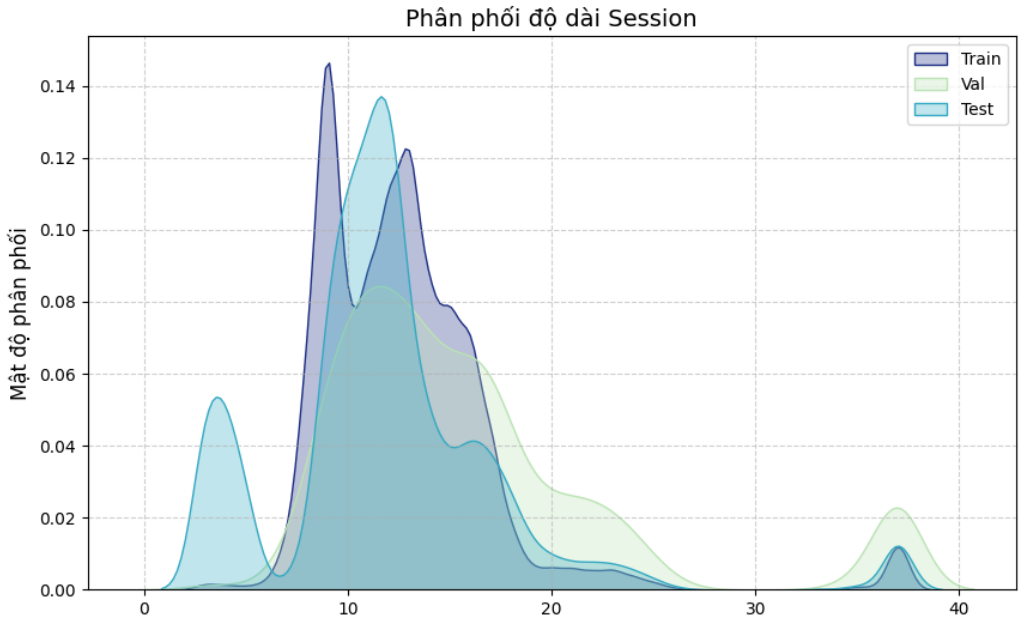

Hình 8: Biểu đồ thể hiện phân phối độ dài các session từ 3 tập: Train, Validation, Test

Hình 8 thể hiện chiều dài chuỗi giữa các tập dữ liệu bộc lộ sự dịch chuyển phân phối rõ rệt. Trong khi tập train có đỉnh phân phối ở khoảng mốc 9 hành động, tập val và test hội tụ về khoảng 12 hành động, phản ánh hành vi mua sắm chuẩn hóa hơn ở giai đoạn sau.

Đáng chú ý, phân phối tập test xuất hiện một đỉnh phụ đột biến ở mốc chuỗi rất ngắn (khoảng ≤ 5 hành động). Nhóm này áp đảo với hơn 4000 mẫu trên Test nhưng lại cực kỳ thưa thớt ở tập train/val. Đây là hiện tượng covariate shift điển hình, có thể bắt nguồn từ các chiến dịch flash sale hoặc tối ưu UI/UX làm luồng mua hàng ngắn lại. Phát hiện này là bằng chứng định lượng then chốt để chúng tôi áp dụng chiến lược **oversampling** (nhân bản 40 lần các chuỗi ngắn ở tập train), ép mô hình học tốt các tương tác thưa thớt và ngăn ngừa rủi ro suy giảm độ chính xác trên môi trường thực tế.

D. Phân tích biến động kết quả và chi tiết các lượt huấn luyện

Khi chạy thử nghiệm các mô hình học sâu, dù đã thiết lập các tham số hạt giống ngẫu nhiên (*random seed*) để đảm bảo tính tái lập (chi tiết tại đây), chúng tôi vẫn ghi nhận sự biến động nhẹ về kết quả giữa các lần chạy. Điều này xuất phát từ hai nguyên nhân kỹ thuật cốt lõi:

- **Tối ưu hóa phần cứng GPU:** Khi huấn luyện trên GPU, thư viện cuDNN của NVIDIA tối ưu hóa tốc độ bằng cách sử dụng các thao tác *Atomic Add* (Cộng nguyên tử) trên nhiều luồng (*threads*) chạy song song. Việc luồng nào hoàn thành tính toán và ghi dữ liệu vào bộ nhớ trước là hoàn toàn ngẫu nhiên, phụ thuộc vào trạng thái vi mô của phần cứng tại từng mili-giây.
- **Sai số làm tròn dấu phẩy động (*Floating-point*):** Mặc dù trong toán học lý tưởng $(A + B) + C = A + (B + C)$, nhưng trong kiến trúc máy tính, việc thay đổi thứ tự cộng sẽ sinh ra sai số làm tròn cực nhỏ. Trải qua hàng chục *epochs* với hàng nghìn tham số, các sai số này tích lũy (hiệu ứng cánh bướm) khiến quỹ đạo *Gradient Descent* bị lệch nhẹ, dẫn đến sự khác biệt ở các số thập phân cuối cùng của hàm Loss hoặc F1-Score.

Để đảm bảo tính khách quan và minh bạch trong việc đánh giá, chúng tôi tiến hành huấn luyện độc lập 4 lượt (*trials*) cho mỗi mô hình đề xuất. Các bảng dưới đây ghi nhận kết quả chi tiết từng lượt, kết quả tốt nhất (**Best**), trung bình (**Average**), và độ lệch/phương sai (**Variance**).

Thời gian chạy được ghi chú tại tiêu đề mỗi bảng là ước tính trung bình cho một lượt huấn luyện trên nền tảng GPU NVIDIA Tesla T4 của Kaggle. Thời gian thực tế có thể thay đổi tùy tình trạng hệ thống, nhưng đảm bảo không vượt quá 1.5 lần thời gian ước tính.

Các mô hình cơ sở RNN, LSTM và GRU cũng được chạy 4 lượt để so sánh công bằng với các mô hình đề xuất. Tuy nhiên, do kết quả trên tập Validation thấp cũng như giới hạn số lần nộp bài của cuộc thi nên các mô hình cơ sở sẽ không có kết quả trên tập Public Test cũng như không được đề cập trong báo cáo này. Chi tiết đầy đủ có thể xem tại đây

Bảng VIII: Chi tiết 4 lượt chạy TAANet (TB: 54m46s)

Metric	Trial 1	Trial 2	Trial 3	Trial 4	Best	Avg	Var
F1 Attr 1	0.9989	0.9989	1.0000	1.0000	1.0000	0.9995	0.0006
F1 Attr 2	0.9999	0.9999	0.9994	0.9994	0.9999	0.9997	0.0001
F1 Attr 3	0.9983	0.9983	0.9980	0.9980	0.9983	0.9982	0.0001
F1 Attr 4	0.9928	0.9928	0.9927	0.9927	0.9928	0.9928	0.0001
F1 Attr 5	0.9993	0.9993	0.9994	0.9994	0.9994	0.9993	0.0001
F1 Attr 6	0.9991	0.9991	0.9992	0.9992	0.9992	0.9991	0.0001
Val EM	0.9968	0.9968	0.9967	0.9967	0.9968	0.9967	0.0001
Pub Test EM	0.9574	0.9574	0.9579	0.9579	0.9579	0.9577	0.0003

Bảng IX: Chi tiết 4 lượt chạy TACNet (TB: 35m50s)

Metric	Trial 1	Trial 2	Trial 3	Trial 4	Best	Avg	Var
F1 Attr 1	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.0000
F1 Attr 2	1.0000	1.0000	0.9999	0.9999	1.0000	0.9999	0.0001
F1 Attr 3	0.9987	0.9986	0.9982	0.9982	0.9987	0.9984	0.0002
F1 Attr 4	0.9890	0.9924	0.9944	0.9972	0.9972	0.9932	0.0008
F1 Attr 5	0.9993	0.9985	0.9993	0.9993	0.9993	0.9991	0.0004
F1 Attr 6	0.9993	0.9989	0.9991	0.9991	0.9993	0.9991	0.0002
Val EM	0.9992	0.9968	0.9972	0.9969	0.9992	0.9975	0.0011
Pub Test EM	0.9675	0.9662	0.9581	0.9735	0.9735	0.9663	0.0061

Bảng X: Chi tiết 4 lượt chạy TARNet (TB: 22m37s)

Metric	Trial 1	Trial 2	Trial 3	Trial 4	Best	Avg	Var
F1 Attr 1	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.0000
F1 Attr 2	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.0000
F1 Attr 3	0.9987	0.9988	0.9987	0.9986	0.9988	0.9987	0.0001
F1 Attr 4	0.9972	0.9934	0.9945	0.9972	0.9972	0.9956	0.0017
F1 Attr 5	0.9993	0.9991	0.9993	0.9994	0.9994	0.9993	0.0001
F1 Attr 6	0.9992	0.9992	0.9989	0.9992	0.9992	0.9991	0.0001
Val EM	0.9976	0.9975	0.9974	0.9976	0.9976	0.9975	0.0001
Pub Test EM	0.9654	0.9703	0.9746	0.9703	0.9746	0.9701	0.0033

Bảng XI: Chi tiết 4 lượt chạy TAGNet (TB: 30m28s)

Metric	Trial 1	Trial 2	Trial 3	Trial 4	Best	Avg	Var
F1 Attr 1	1.0000	1.0000	1.0000	1.0000	1.0000	1.0000	0.0000
F1 Attr 2	1.0000	0.9998	1.0000	0.9998	1.0000	0.9999	0.0001
F1 Attr 3	0.9983	0.9984	0.9979	0.9982	0.9984	0.9982	0.0002
F1 Attr 4	0.9950	0.9949	0.9972	0.9949	0.9972	0.9958	0.0011
F1 Attr 5	0.9994	0.9994	0.9993	0.9993	0.9994	0.9993	0.0001
F1 Attr 6	0.9992	0.9989	0.9992	0.9990	0.9992	0.9991	0.0002
Val EM	0.9974	0.9971	0.9969	0.9968	0.9974	0.9971	0.0002
Pub Test EM	0.9692	0.9704	0.9725	0.9720	0.9725	0.9708	0.0013

E. Trực quan hóa mạng lưới nhân quả

Nhằm cung cấp một góc nhìn đa chiều về "topo học" của luồng khách hàng từ mức độ vi mô (ít kết nối) đến vĩ mô (dày đặc kết nối), Phụ lục này trình bày chi tiết sự biến đổi của đồ thị khi thay đổi số lượng cạnh (*edges*) được giữ lại. Hình 9 minh họa cấu trúc mạng lưới tương ứng với các ngưỡng 50, 100, 150 và 200 cạnh có trọng số Attention cao nhất. Toàn bộ các đồ thị trong phụ lục này đều được trích xuất trực tiếp từ trọng số của kiến trúc TAGNet tại lượt huấn luyện thứ 3 (Trial 3) - lượt chạy đạt hiệu suất Exact-Match tốt nhất trong toàn bộ quá trình thực nghiệm.

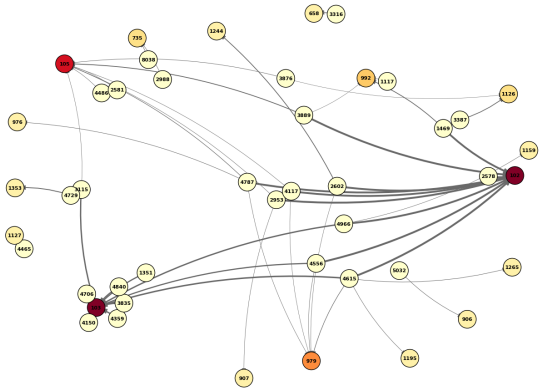

(a) Top 50 cạnh mạnh nhất

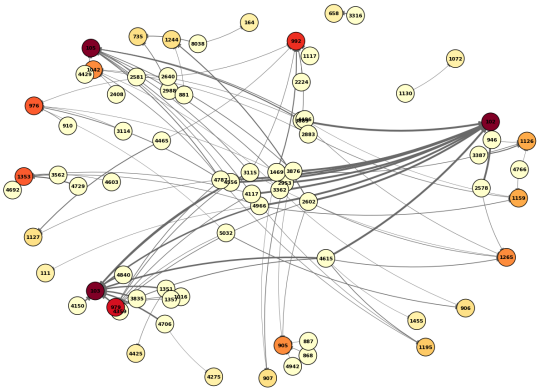

(b) Top 100 cạnh mạnh nhất

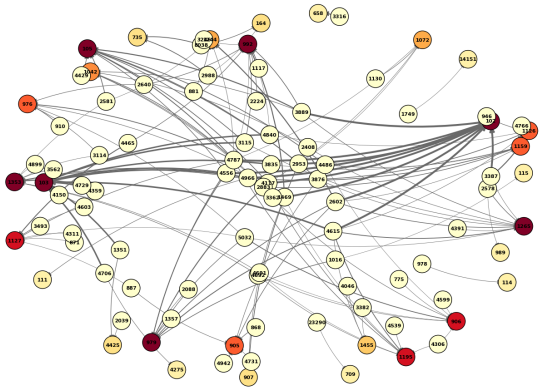

(c) Top 150 cạnh mạnh nhất

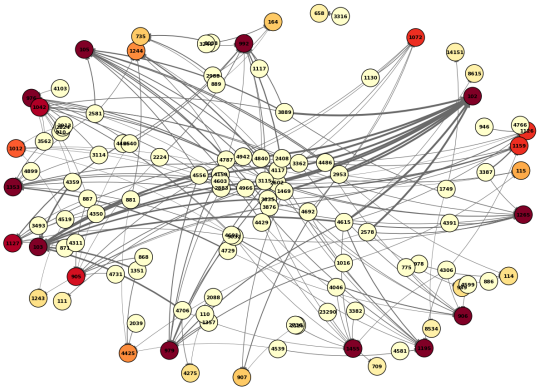

(d) Top 200 cạnh mạnh nhất

Hình 9: Sự tiến hóa của mạng lưới nhân quả khi tăng dần số lượng cạnh trọng yếu. Có thể thấy rõ các nút thắt (*bottlenecks*) như mã `102` luôn duy trì vai trò trung tâm cốt lõi, bất chấp việc đồ thị xuất hiện thêm nhiều luồng hành vi phụ trợ ở các ngưỡng cạnh lớn hơn.

F. Phân tích hành vi gây nhiễu trên đa thuộc tính

Chúng tôi tiến hành mổ xẻ hiện tượng mô hình dồn sự chú ý vào các "cú lừa" (*Distractors*) khi dự báo sai trên các thuộc tính khác nhau. Phụ lục này cung cấp các biểu đồ đối chiếu mức độ tập trung Attention giữa nhóm dự đoán Đúng và Sai cho các thuộc tính khác (Hình 10). Toàn bộ các đồ thị trong phụ lục này đều được trích xuất trực tiếp từ trọng số của kiến trúc TAGNet tại lượt huấn luyện thứ 3 (Trial 3) - lượt chạy đạt hiệu suất Exact-Match tốt nhất trong toàn bộ quá trình thực nghiệm.

Lưu ý rằng, phân tích này chỉ được thực hiện trên các thuộc tính 3, 4, 5 và 6. Đối với thuộc tính 1 và 2, do kiến trúc TAGNet (Trial 3) đã đạt độ chính xác (*Accuracy*) tuyệt đối 1.0000 trên tập Validation, hệ thống không ghi nhận bất kỳ mẫu dự đoán sai nào để tiến hành đối chiếu phân tách trọng số.

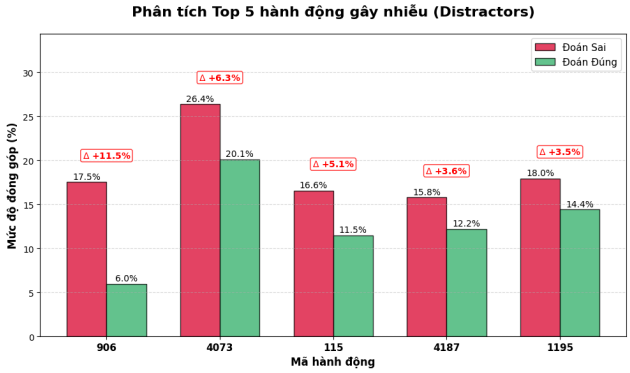

(a) Thuộc tính 3

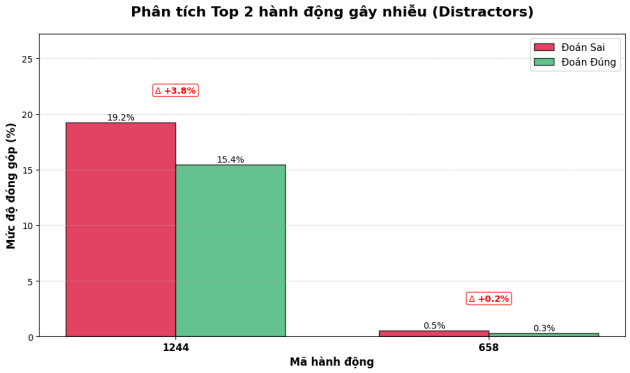

(b) Thuộc tính 4

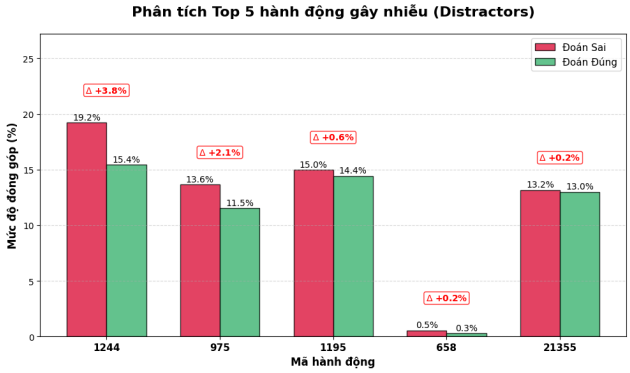

(c) Thuộc tính 5

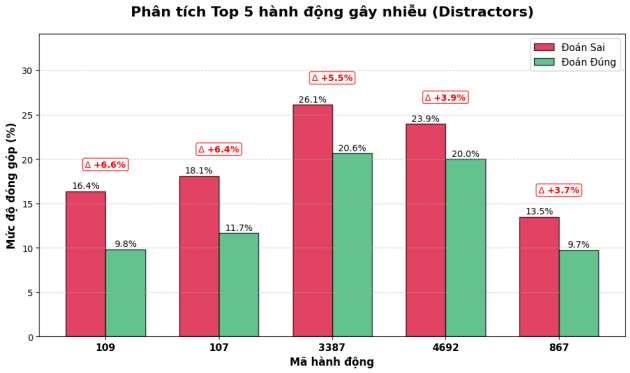

(d) Thuộc tính 6

Hình 10: Biểu đồ đối chiếu Attention vào các hành động gây nhiễu giữa dự đoán Đúng/Sai trên 4 thuộc tính. Thuộc tính 1 và 2 không được biểu diễn do mô hình dự đoán chính xác tuyệt đối 100%.